BM-311 Bilgisayar Mimarisi

Hazırlayan: M.Ali Akcayol
Gazi Üniversitesi
Bilgisayar Mühendisliği Bölümü

Konular

- Hafıza sistemleri karakteristikleri
- Hafıza hiyerarşisi
- Önbellek prensipleri
- Önbellek tasarım bileşenleri
  - Cache size
  - Mapping function
  - Replacement algorithms
  - Write policy
  - Line size
  - Number of caches

Hafıza sistemleri karakteristikleri

- Location
  - Internal (regs, cache, main memory)
  - External (optical disk, magnetic disk, tape)
- Capacity
  - Number of words
  - Number of bytes
- Unit of transfer
  - Word
  - Block
- Access method
  - Sequential
  - Direct
  - Random
  - Associative
- Performance
  - Access time
  - Cycle time
  - Transfer rate
- Physical type
  - Semiconductor
  - Magnetic
  - Optical
  - Magneto-optical
- Physical characteristics
  - Volatile/nonvolatile
  - Erasable/nonerasable
- Organization
  - Memory modules

Hafıza sistemleri karakteristikleri

Location

- **Internal:**
  - Register'lar, control unit memory, cache, main memory.
- **External:**
  - HDD, tape, I/O kontrol ile erişilenler.

Hafıza sistemleri karakteristikleri

Capacity

- **Number of words:**
  - Toplam satır sayısını ifade eder.
  - Genellikle main memory için kullanılır.
  - Bir word 8, 16 veya 32 bit olabilir.
- **Number of bytes:**
  - İkincil depolama birimlerinde kapasite byte olarak ifade edilir.

Hafıza sistemleri karakteristikleri

Unit of transfer

- **Word:**
  - Bir seferde bir word boyutunda veri okunur veya yazılır.
  - Main memory için kullanılır.
- **Block:**
  - Bir seferde bir blok veri okunur veya yazılır.
  - External depolama birimleri için kullanılır.

Hafıza sistemleri karakteristikleri

Access method

- **Sequential:** Okuma/yazma mekanizması, mevcut bulunulan konumdan istenen hedef konuma kadar tüm kayıtları okuyarak gider (Tape).
- **Direct:** İstenen konuma doğrudan konumlanılır. İstenen konum okuma/yazma mekanizmasının altına gelene kadar beklenir. Erişim süresi önceki bulunulan konuma bağlıdır (HDD, CD).
- **Random:** İstenen konuma doğrudan gidilir. Erişim süresi önceki konuma bağlı değildir (Main memory).
- **Associative:** Arama adrese göre değil içeriğe göre yapılır. Aranan veriyle tüm hafıza alanları eşzamanlı karşılaştırılır (Cache).

Hafıza sistemleri karakteristikleri

Performance

- **Access time (latency):**
  - RAM için adres bilgisinin verilmesinden verinin alınmasına/yazılmasına başlayıncaya kadar geçen süredir.
  - Diğerleri için okuma/yazma mekanizmasının istenen konuma ulaşması için geçen süredir.
- **Memory cycle time:**
  - RAM için iki erişim süresi arasındaki toplam süredir.
- **Transfer rate:**
  - Veri aktarım hızıdır.
  - RAM için **(1 / cycle time) * block size** ile ifade edilir.
  - Non-random access memory için $T_n = T_A + (n / R)$ ile ifade edilir.
  - T_A ortalama erişim süresi; n bit sayısı ve R aktarım hızı (bps).
  - T_n, n adet bit için okuma veya yazma süresidir.

Hafıza sistemleri karakteristikleri

Physical type

- **Semiconductor:**
  - Random access memory'lerde kullanılır.
- **Magnetic:**
  - Disk ve tape ünitelerinde kullanılır.
- **Optical ve magneto-optical:**
  - CD ve DVD'lerde kullanılır.

Hafıza sistemleri karakteristikleri

Physical characteristics

- **Volatile/nonvolatile:**
  - Elektrik kesildiğinde veri kaybolan (semiconductor)
  - Elektrik kesildiğinde veri kaybolmayan (magnetic-surface)
- **Erasable/nonerasable:**
  - İçeriği silinebilen (EEPROM)
  - İçeriği silinemeyen (ROM)

Hafıza sistemleri karakteristikleri

Organization

- Word oluşturmak için bitlerin yerleşimini ifade eder (interleaved, sequential).

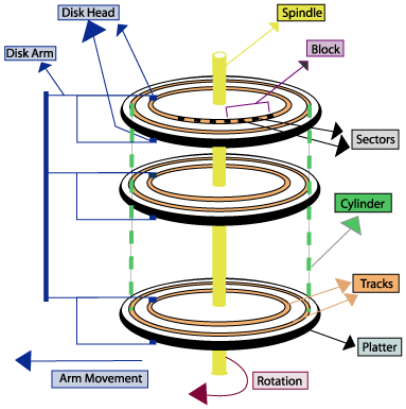

"Database Management Systems", Ramakrishnan & Gehrke, p. 307 Redrawn by L. Kisinski

Konular

- Hafıza sistemleri karakteristikleri
- Hafıza hiyerarşisi
- Önbellek prensipleri
- Önbellek tasarım bileşenleri
  - Cache size
  - Mapping function
  - Replacement algorithms
  - Write policy
  - Line size
  - Number of caches

Hafıza hiyerarşisi

- **CPU tarafından** hafıza birimlerine **erişim süresi kısaldıkça, bit başına maliyet artar.**
- **Kapasitesi büyük** hafıza birimlerinin **bit başına maliyeti daha düşüktür.**
- **Kapasitesi büyük** hafıza birimlerine **erişim süresi daha büyüktür.**

Hafıza hiyerarşisi

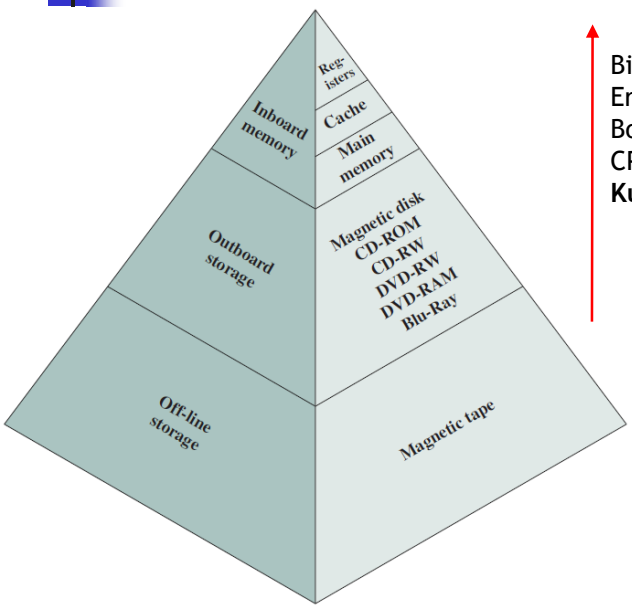

Birim maliyet artar.
Erişim süresi azalır.
Boyut azalır.
CPU'ya yaklaşır.
Kullanım sıklığı artar.

Hafıza hiyerarşisi

Örnek:

- Bir CPU iki seviyeli hafızaya erişiyor.
- **Birinci seviye 1000 word** ve **ikinci seviye 100.000 word** kapasitededir.
- Birinci seviye hafızaya **erişim süresi 0,01μs,** ikinci seviye hafızaya **erişim süresi 0,1μs** dir.
- CPU ilk önce birinci seviyeye, yoksa ikinci seviyeye erişmektedir.

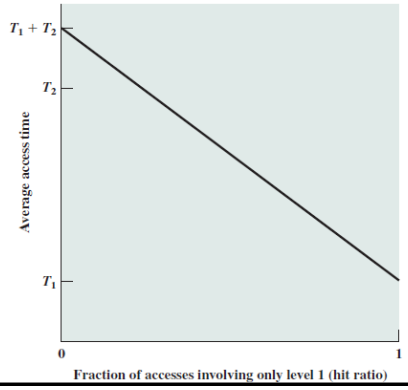

Hafıza hiyerarşisi

Örnek:

- Grafikte, verinin birinci seviye hafızada bulunma oranına göre erişim süresi görülmektedir. **Birinci seviye önbelleği ifade eder.**
- Verinin birinci seviyede bulunma oranı %95 ise ortalama erişim süresi nedir?

Ortalama erişim süresi = (0,95)(0,01μs) + (0,05)(0,01μs + 0,1μs)

= 0,0095 + 0,0055 = 0,015μs

Ortalama erişim süresi **0,01μs** ye daha yakındır, çünkü %95 oranında birinci seviyede bulunmuştur.

Grafikte, T_1 **birinci seviyeye** T_2 **ikinci seviyeye erişim süresidir.**

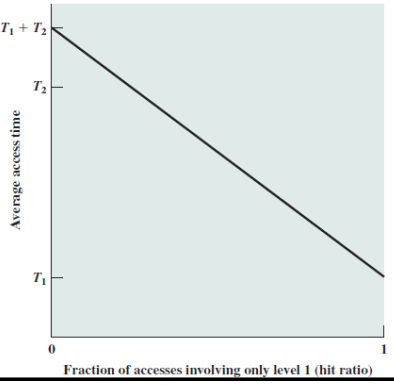

Hafıza hiyerarşisi

CPU'nun erişim sıklığına göre hafıza hiyerarşisi

- Registers
- L1 Cache
- L2 Cache
- L3 Cache
- Main memory
- Disk cache
- Disk
- Optical
- Tape

Konular

- Hafıza sistemleri karakteristikleri
- Hafıza hiyerarşisi
- Önbellek prensipleri
- Önbellek tasarım bileşenleri
  - Cache size
  - Mapping function
  - Replacement algorithms
  - Write policy
  - Line size
  - Number of caches

Önbellek prensipleri

- Önbellek, **main memory ile CPU arasına yerleştirilir.**
- CPU önce önbelleğe erişir, aranan veri yoksa main memory'ye erişir.
- Eğer aranan veri main **memory'de ise** içinde bulunduğu blok ile birlikte alınır. **Önbelleğe ve CPU'ya aktarılır.**

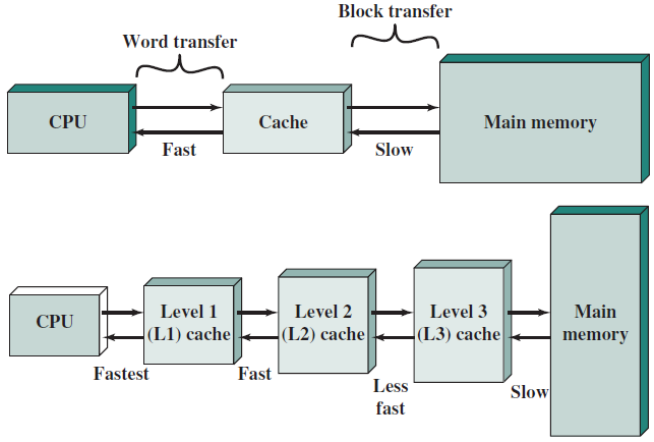

Önbellek prensipleri

- Önbellek ve main memory yapısı şekilde görülmektedir.

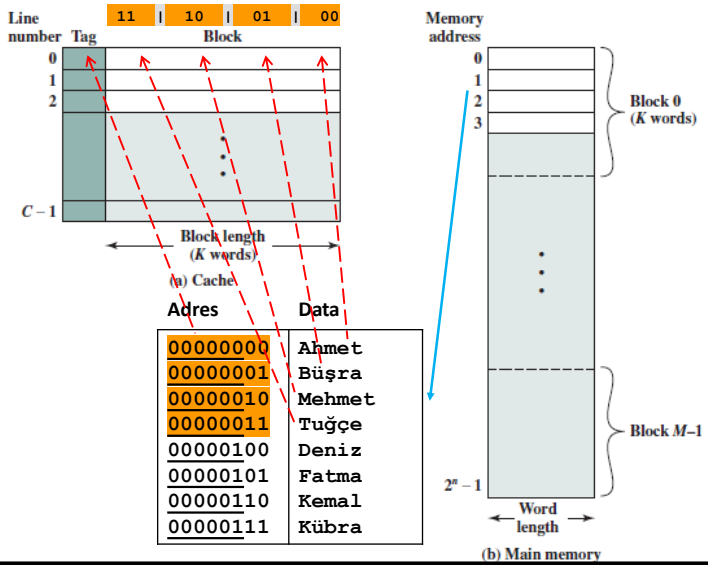

Adres	Data
00000000	Ahmet
00000001	Büşra
00000010	Mehmet
00000011	Tuğçe
00000100	Deniz
00000101	Fatma
00000110	Kemal
00000111	Kübra

M blok
Her blok ***K*** word

$M = 2^n / K$
$C << M$

Önbellek prensipleri

Önbellek işlemi

- CPU bir adres içeriğini ister.
- Önbelleğe bakılır.
- Önbellekte bulunursa alınır.
- Önbellekte yoksa hafızada içinde bulunduğu blok alınır ve önbelleğe aktarılır.
- Önbellekten CPU'ya aktarılır.

Önbellek prensipleri

Önbellek erişimi

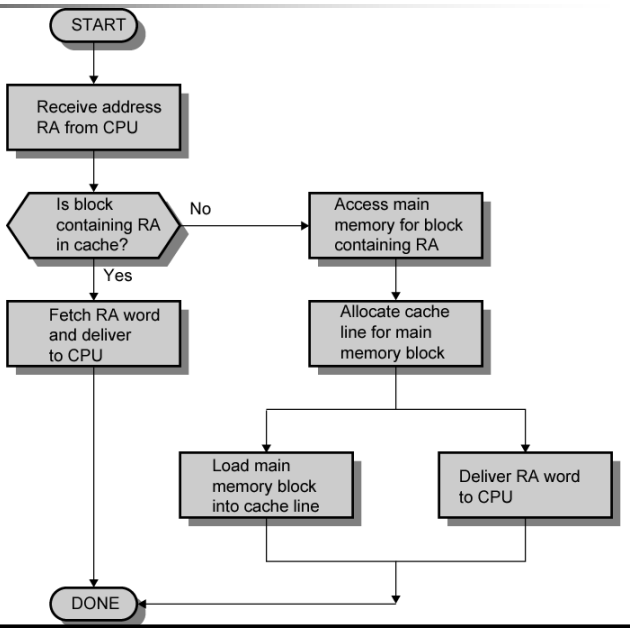

Önbellek prensipleri

Önbellek organizasyonu

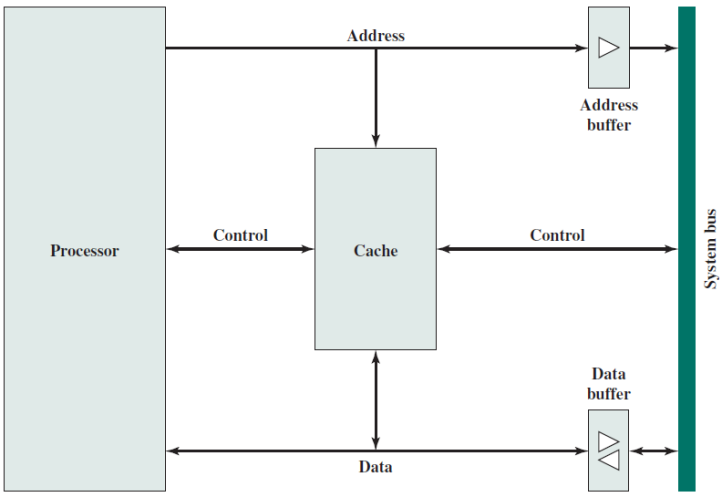

Konular

- Hafıza sistemleri karakteristikleri
- Hafıza hiyerarşisi
- Önbellek prensipleri
- Önbellek tasarım bileşenleri
  - Cache size
  - Mapping function
  - Replacement algorithms
  - Write policy
  - Line size
  - Number of caches

Önbellek tasarım bileşenleri

- Cache size
  - Cache satır boyutu
  - Cache satır sayısı
- Mapping function
  - Direct
  - Associative
  - Set associative
- Replacement algorithms
  - Least recently used (LRU)
  - First in first out (FIFO)
  - Least frequently used (LFU)
  - Random
- Write policy
  - Write through
  - Write back
  - Write once
- Line size
  - Satıra alınan blok boyutu
- Number of caches
  - Single or multilevel
  - Unified or split

Önbellek tasarım bileşenleri

Cache size

- **Önbellek boyutu azaldıkça** toplam **maliyet düşer.**
- **Önbellek boyutu arttıkça** hit oranı arttığı için **veriye ortalama erişim süresi düşer.**
- **Önbellek boyutu arttıkça** kullanılan **devre daha karmaşık hale gelir** ve az da olsa her bir veriye ulaşma süresi artmaya başlar.

Önbellek tasarım bileşenleri

Mapping function

- **Önbellekteki satır sayısı main memory'den çok az** olduğu için eşleştirme fonksiyonu kullanılarak aktarma yapılır.
- Mapping function **hafızadaki bir bloğun önbelleğe nasıl yerleştirileceğini belirler.**
- **Direct, full associative** ve **set associative** olarak üç yöntem kullanılır.

Önbellek tasarım bileşenleri

Mapping function

- Direct mapping ve associative mapping

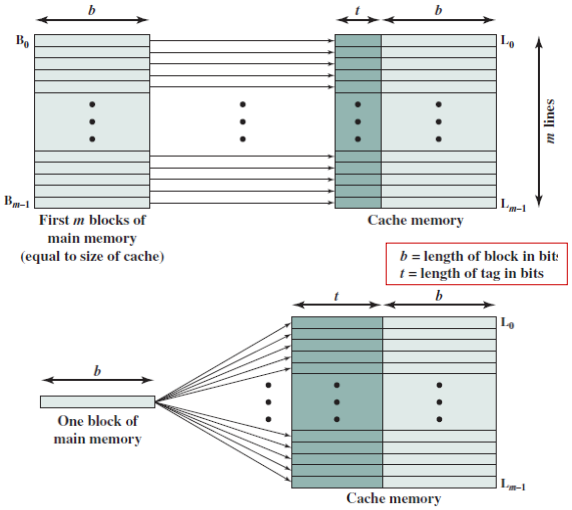

Önbellek tasarım bileşenleri

Direct mapping

- Şekilde **önbellek satır boyutu 32-bit** alınmıştır.
- Hafızada **her blok 4-byte** kapasitedir.
- Önbellekte **satır adresleme 3-bit** ile yapılmaktadır.
- Hafızadaki **256 blok** önbellekteki toplam **8 satıra** eşleştirilmektedir.
- **Önbellekteki her satırı 32 blok** paylaşmaktadır.

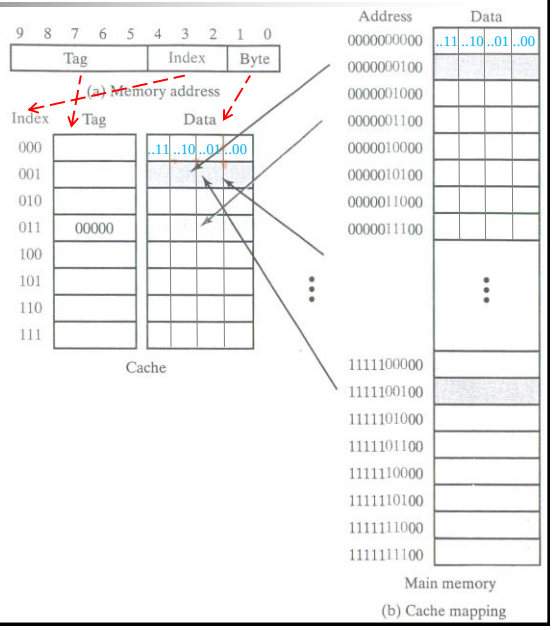

Önbellek tasarım bileşenleri

Örnek:

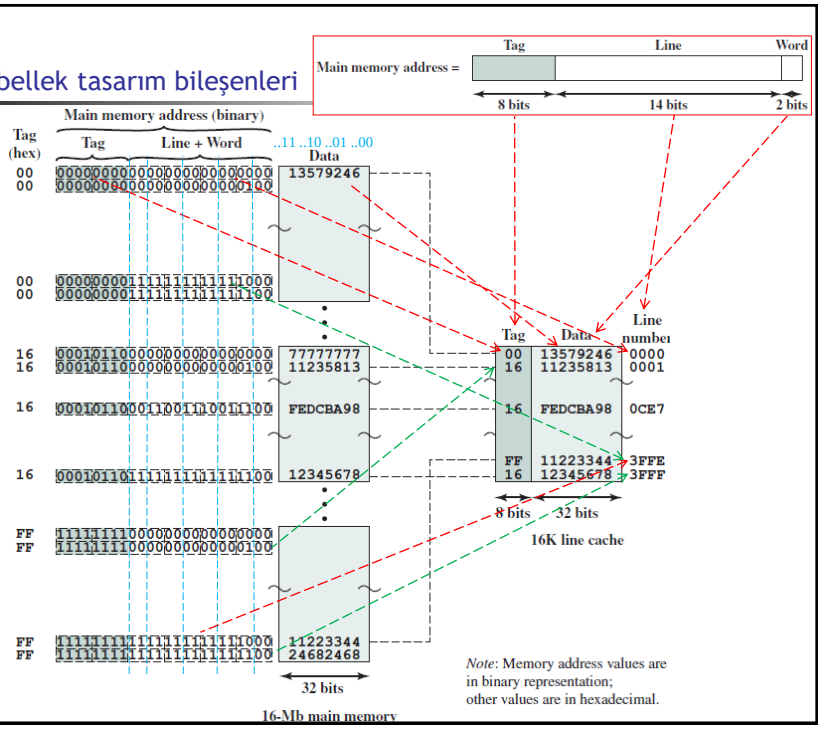

Önbellek tasarım bileşenleri

Direct mapping – devam

- Eşleştirme modüler aritmetiğe göre yapılır.

$i = j \bmod m$

i = önbellek satır numarası
j = main memory blok numarası
m = önbellekteki satır sayısı

- Her hafıza adresi 3 alandan oluşur. **Tag, Line** ve **Word**.
- **Line** önbellekte satırı seçmek için, **tag** seçilen satırın etiketini belirtmek için, **word** bulunan satırın bir elemanını seçmek için kullanılır.

Önbellek tasarım bileşenleri

Direct mapping – devam

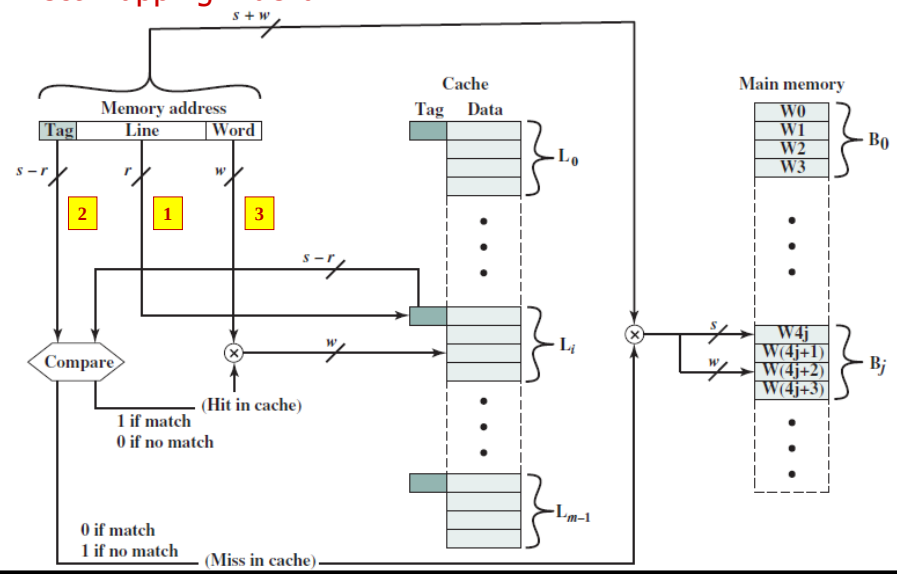

Önbellek tasarım bileşenleri

Direct mapping – devam

- Adres boyutu = $(s+w)$ bit
- Adreslenebilir alan sayısı = 2^{s+w} word
- Blok boyutu = satır boyutu = 2^w word
- Hafızadaki blok sayısı = $(2^{s+w}) / (2^w) = 2^s$ word
- Önbellekteki satır sayısı = 2^r
- Önbellek boyutu = 2^{r+w}
- Tag boyutu = $(s - r)$ bit

Avantaj / dezavantaj

- Oluşturmak **basit ve ucuzdur.**
- **Bir blok sadece bir satıra yazılabilir.**
- Aynı satıra eşleşen iki blok sürekli çalıştığında performans düşer.

Önbellek tasarım bileşenleri

Full associative mapping

- Direct mapping'teki bir bloğun sadece bir satıra eşleştirilmesi dezavantajı ortadan kaldırılır.
- **Bir blok önbellekte istenilen satıra eşleştirilir.**
- Aranan bilginin önbellekte olup olmadığı tüm satırlarda eşzamanlı kontrol edilir (içerik arama).
- Hafızadan alınan bloğun önbellekte hangi satıra yazılacağı **replacement algoritması** ile belirlenir.

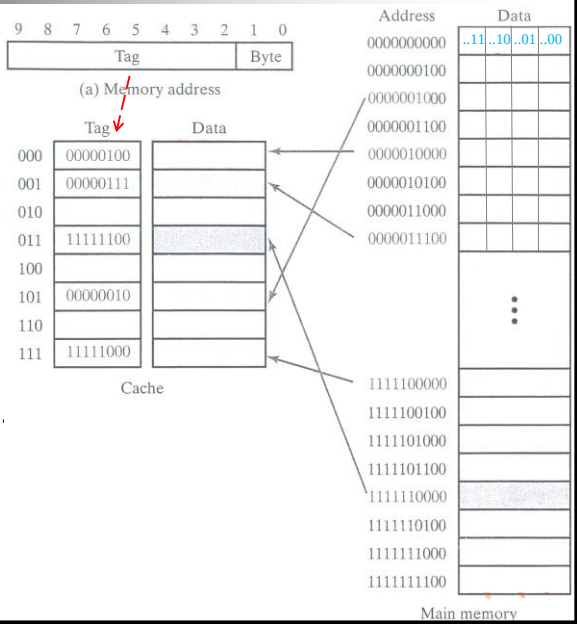

Önbellek tasarım bileşenleri

Örnek:

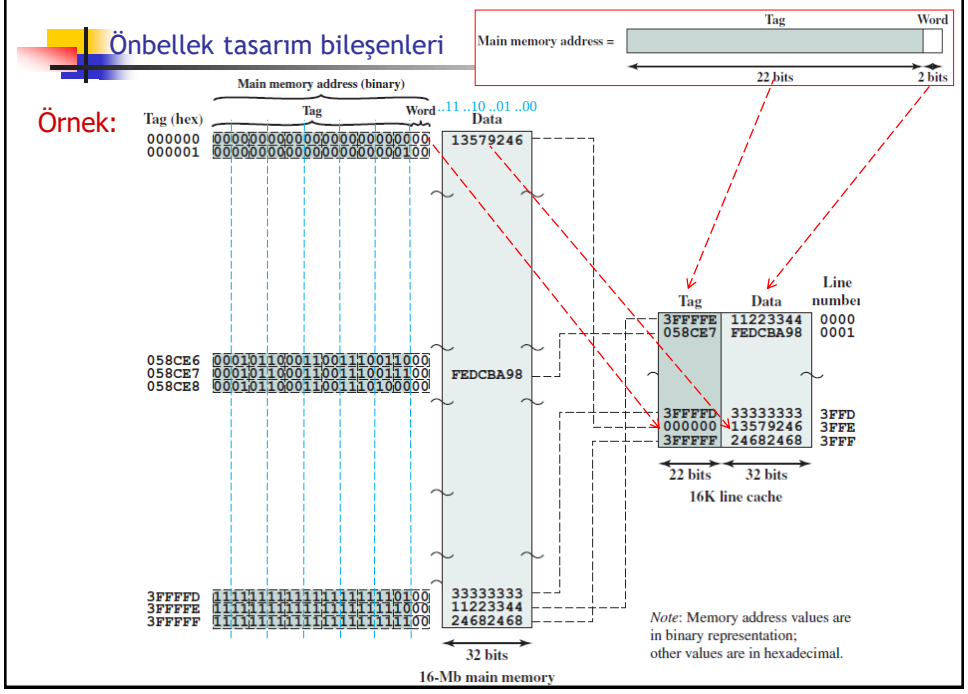

Önbellek tasarım bileşenleri

Full associative mapping – devam

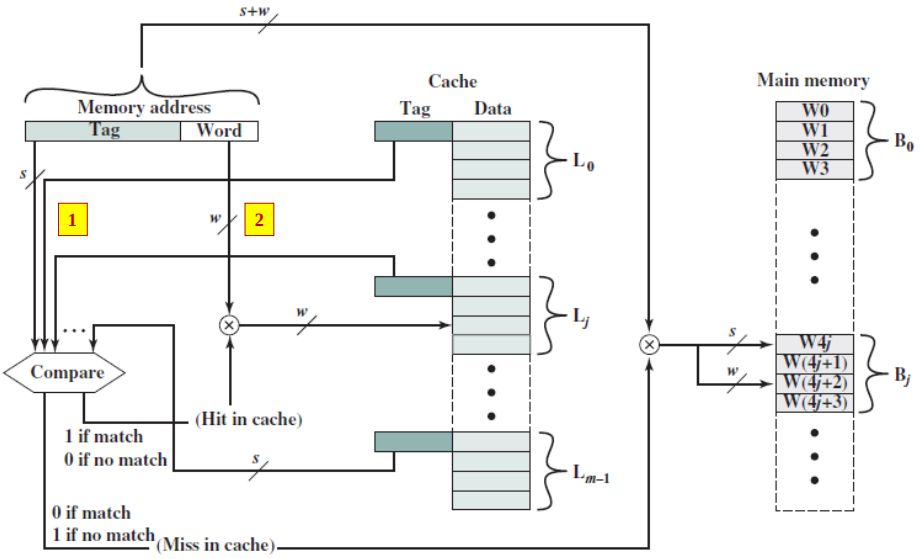

Önbellek tasarım bileşenleri

Full associative mapping – devam

- Adres boyutu = $(s+w)$ bit
- Adreslenebilir alan sayısı = 2^{s+w} word
- Blok boyutu = satır boyutu = 2^{w} word
- Hafızadaki blok sayısı = $(2^{s+w}) / (2^{w}) = 2^{s}$ word
- Önbellekteki satır sayısı = tanımlı değil
- Tag boyutu = s bit

Avantaj / dezavantaj

- Yapısı karmaşıktır.
- Bir blok uygun olan bir satıra yazılabilir.
- Önbellekte eşzamanlı arama hızı düşüktür.

Önbellek tasarım bileşenleri

Set associative mapping

- Önbellek satırları birden fazla blok ile oluşturulur.

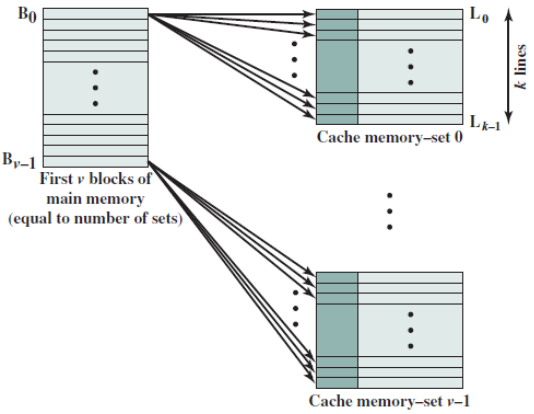

Önbellek tasarım bileşenleri

Set associative mapping

- Direct mapping ve associative mapping birleşimidir.
- **Önbellek belirli sayıda kümeden oluşur.**
- Her küme kendi içinde associative yapıdadır ve hafızadan alınan bloğun kümede hangi satıra yazılacağı **replacement algoritması** ile belirlenir.

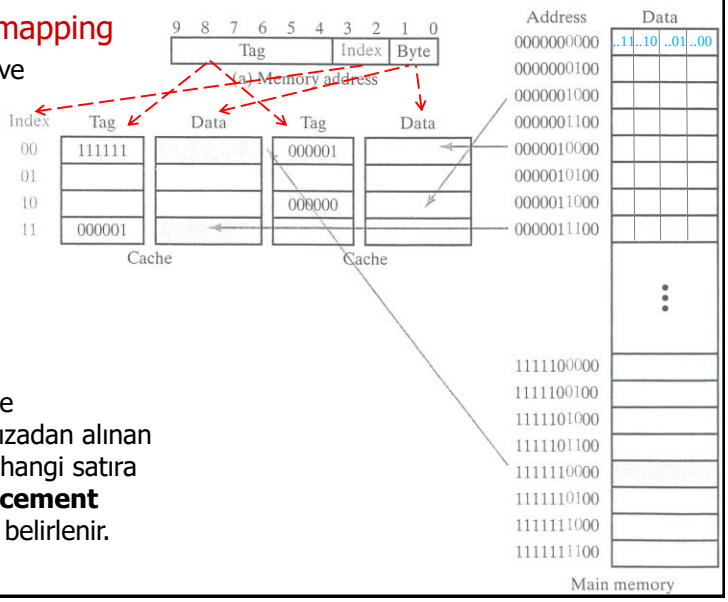

Önbellek tasarım bileşenleri

Örnek:

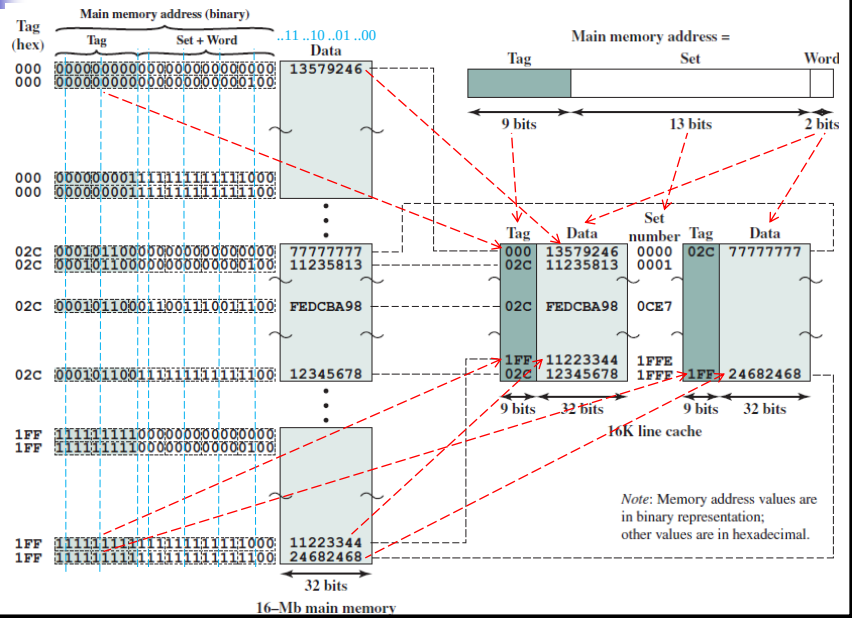

Önbellek tasarım bileşenleri

Set associative mapping – devam

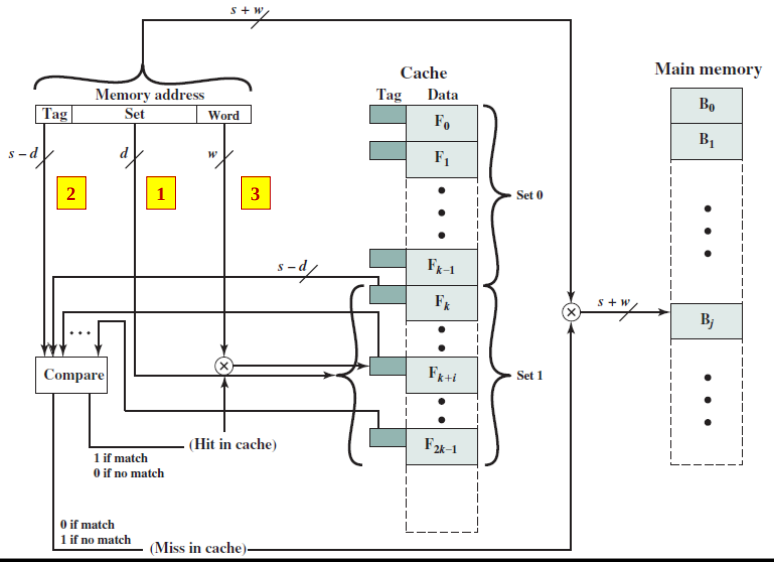

Önbellek tasarım bileşenleri

Set associative mapping– devam

- Adres boyutu = $(s+w)$ bit
- Adreslenebilir alan sayısı = 2^{s+w} word
- Blok boyutu = satır boyutu = 2^{w} word
- Hafızadaki blok sayısı = $(2^{s+w}) / (2^{w}) = 2^{s}$ word
- Kümedeki satır sayısı = k
- Küme sayısı = 2^{d}
- Önbellekteki boyutu = $k \,.\, 2^{d}$
- Tag boyutu = $(s\text{-}d)$ bit

Avantaj / dezavantaj

- Yapısı direct mapping'e göre karmaşıktır.
- Bir blok sadece kendisine ait bir kümedeki istenilen satıra yazılabilir.
- Önbellekte küme içinde eşzamanlı arama hızı düşüktür.

Önbellek tasarım bileşenleri

Cache boyutuna göre hit ratio (direct ve set associative)

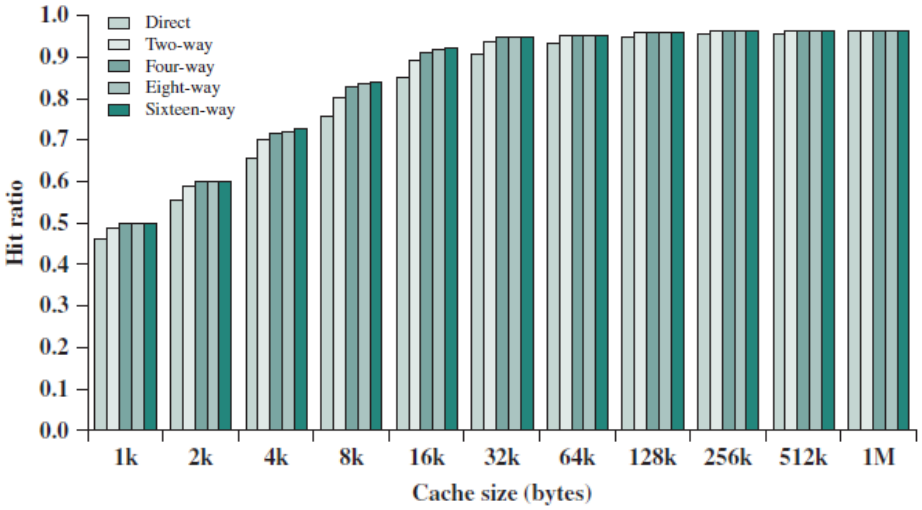

Önbellek tasarım bileşenleri

Replacement algorithms

- **Direct mapping'te** sadece bir satır seçilebildiği için replacement algoritması kullanılmaz.
- **Full associative** ve **set associative** eşleştirmede replacement algoritmaları kullanılır.
- **Least recently used (LRU):**
  - En uzun süre kullanılmayan satıra yazılır.
  - Her satır için USE field kullanılır.
- **First in first out (FIFO):**
  - İlk gelen satıra yazılır.
- **Least frequently used (LFU):**
  - En az sıklıkta kullanılan satıra yazılır.
  - Her satır için counter kullanılır.
- **Random:**
  - Rastgele bir satır seçilir ve o satıra yazılır.

Önbellek tasarım bileşenleri

Write policy

- Önbellekteki **veri değiştiyse** üzerine veri yazılmadan **hafızaya aktarılmalıdır.**
- Eğer hafıza birden fazla CPU tarafından ortak kullanılıyorsa, önbellekteki güncel verinin hafızaya aktarılma yöntemi önemlidir.
- **Write through:** Önbellekteki her yazma işlemi doğrudan hafızaya da aktarılır.
- Çok işlemcili sistemlerde bus sürekli izlenir ve değişiklikler aktarılır.
- Bus üzerindeki trafik yüksektir.
- **Write back:** Önbellekteki veri değiştiği anda değil, önbellekten atılacağı anda hafızaya yazılır. Her satır için UPDATE field kullanılır.
- Bus trafiği write through'a göre daha düşüktür.
- **Write once:** Önbellekteki ilk değişiklikler hemen yazılır (write through), diğerleri atılırken yazılır (write back).

Önbellek tasarım bileşenleri

Line size

- Önbellekte bir veri bulunamadığında, hafızadan sadece o veri değil ait olduğu blok alınır.
- Satır boyutu arttıkça **başlangıçta hit ratio artar** daha **sonra düşmeye başlar.**
- Blok boyutu arttıkça **yakın zamanda kullanılmayacak verilerde alınmaya başlar.**

Önbellek tasarım bileşenleri

Number of caches

- Önbellek çok seviyeli ve veri ile komut için ayrı ayrı oluşturulabilir.

Multilevel caches

- On-chip ve off-chip olarak oluşturulabilir.
- L1, L2 ve L3 şeklinde üç seviyeli kullanımı vardır.
- On-chip önbellek CPU'nun external bus trafiğini azaltır.

Unified/split caches

- Split önbelleklerde **komut ve data** için ayrı ayrı kısımlar kullanılır.
- Unified önbelleklerde **hit oranı yüksektir.** Çünkü komut ve data arasındaki fetch yoğunluğuna göre kendini update eder.
- Unified önbelleklerde tek kısım olduğundan **yapısı basittir.**
- Split önbelleğin en önemli avantajı, instruction cycle'da **instruction fetch/decode unit** ile **execution unit**'i bağımsız hale getirmesidir. **Pipelining için önemlidir.**

Ödev

- Multicore ve çok işlemcili sistemlerde cache coherence için kullanılan protokoller hakkında detaylı bir araştırma ödevi hazırlayınız.